

位置感知的图嵌入模型研究 (Position-Aware Graph Embedding Model)

陈鸿崢 冯家苇 黄杨峻

17341015 17341035 17341059

一、简介

图嵌入(graph embedding)包括对结点、边或(子)图进行编码映射至低维向量空间,是很多下游预测任务的基础,包括结点分类、连边预测、社群检测等¹。




图 1: 对Karate network进行图嵌入的可视化, 图源DeepWalk [1]。

图嵌入方法主要可分为三类: 基于矩阵分解的方法、随机游走(random walk)和图神经网络(graph neural network, GNN)。最早年使用的是基于矩阵分解的方法,但是计算量通常很大,只能处理图或结点特征维度较小的问题。现在较多使用后两种方法,随机游走通常限制于转导(transductive)的设定,训练测试集属于同一个图;图神经网络则可以用于归纳(inductive)的设定,泛化能力强,可轻松适应未知的图/结点,因而GNN现在也成为应用和研究的热点。GNN已经在推荐系统 [2]、生物医学、程序综合、语义分割、逻辑推断等大量场景得到广泛应用。

但目前的GNN存在以下的问题:

- 从通用的图角度来讲,它具有不规则/非欧(non-Euclidean)结构和幂律分布(power-law)等特性,这与传统深度学习的稠密计算有着巨大差别,可扩展性差,没有办法处理大图。然而现实世界中的社交网络、商品网络往往都是非常庞大的,要在这些图上采用GNN,算法复杂度一定是一个需要考虑的问题。
- 从学习表示的角度来讲,现有的GNN更多捕获的是局部结构特征,而丧失了全局的相对位置信息。这会导致GNN无法很好辨别同构子图结点,在一些预测任务上给出错误的结果。一个简单的例子,一家三口在社交网络上呈现出来的都是三角形,但是GNN会认为

¹如无特殊说明,下文说的图嵌入都是指结点嵌入。由结点嵌入生成边或子图的嵌入也是容易的,因此大多数工作都着重于结点嵌入的研究。

所有这些三角形都是等同的（所有家庭没有区别），做图嵌入时会将这三个结点映射到同样的向量表示。

因此，本课题希望提出一种高效的图嵌入模型，在**保持局部和全局结构信息**的同时，具有**较高的可扩展性**。

二、背景

1. 记号

考虑图 $G(V, E)$ ，在其基础上添加顶点的类别，则形成标注图(labeled graph) $G_L = (V, E, X_{em}, Y)$ ，其中 $X_{em} \in \mathbb{R}^{|V| \times d}$ 为顶点嵌入， $Y \in \mathbb{R}^{|V| \times |C|}$ ， d 为特征维数， Y 为标签集。注意这种写法指 X 和 Y 均为矩阵， X 一共有 $|V|$ 行，每行对应一个顶点的特征向量，有 d 维；并且每个结点可能属于多个类别 $\subset C$ 。图嵌入的目标是学习得到嵌入表示 X_{em} ，或者说映射 $\Phi: V \mapsto X_{em}$ ，使得在低维的嵌入空间中，图结点有很好的**分布式连续表达**，能够很好保持图的邻接结构，即结点向量间的距离能够衡量原图中的邻接关系强弱。这里会涉及到不同的距离度量，不同的度量方式则会产生不同的图嵌入方法。

2. 随机游走

随机游走顾名思义即从图上的一些结点 v 开始向它的邻居进行探索，采样出大量路径 $N_S(v)$ 后，对这些进行路径进行学习。

一个较通用的优化目标如下

$$\max_{\Phi} \sum_{v \in V} \log \Pr(N_S(v) \mid \Phi(v))$$

即在生成的嵌入表示条件下，这种路径出现的概率尽可能大。

DeepWalk [1]最早使用随机游走来做图嵌入任务，每次随机选择一个起始点 v_i ，**随机选择邻居**，做固定长度的随机游走，依据得到的 \mathcal{W}_{v_i} ，做skip-gram，梯度下降更新参数。

node2vec [3]则不再采用DeepWalk每个结点完全随机的方式，而更加**有目的地利用BFS和DFS**进行采样。可以看到这种方法对图的微观和宏观特性做了权衡，通过设置超参数 p 和 q ，能比较有效地学习到图的局部(BFS)和全局(DFS)特征。




图 2: 图源node2vec [3]

不同随机游走最大的差异在于其在每个结点计算转移概率的方式 [4]，这里可用统一的转移概率公式来表达

$$P(e) = P_s(e) \cdot P_d(e, v, w) \cdot P_e(v, w)$$

这是十分直接的公式化，即某一条出边 e 的转移概率，等于静态成分、动态成分、扩展成分三者相乘。详细地说，游走者 w 当前处于结点 v ，

- 静态成分 P_s 只关乎当前的边 e
- 动态成分 P_d 关乎这条边 e 以及游走者过来的路径/状态 w
- 扩展成分 P_e 则不与出边相关

3. 图神经网络

图神经网络的核心思想是从邻居²结点整合特征，通过黑箱网络，对输出拟合。




图 3: 图源Jure Leskovec, [Tutorial - Representation Learning on Networks \(WWW'18\)](#)

现有GNN的传播规则都可表示为 [5]

$$\mathbf{v}_i^{(k+1)} = \gamma \left(\mathbf{v}_i^{(k)}, \text{Agg} \phi(\mathbf{v}_i^{(k)}, \mathbf{v}_j^{(k)}, \mathbf{e}_{j,i}^{(k)}) \right)$$

即包括消息聚合和参数更新两个步骤，其中 Agg 是一个可微、置换不变的函数（求和、求平均、求最值）， γ 和 ϕ 则是可微函数（如MLP）。

最早提出的GCN [6]很好地借鉴了传统CNN中卷积的思想，对网络层共享参数，同时对自身特征进行聚合并做归一化，从而得到了更优的结果。之后的GraphSAGE [7]采用更加一般化的聚合函数，同时考虑合并(concat)自身特征而非相加的方式，进一步提升了GNN的性能。以及各种GNN的变体，如GAT [8]、GGs-NN [9]等，在未经训练时其生成的图嵌入就已经达到随机游走的水准。

²这里的邻居是泛化的邻居，不一定需要在图中真实相邻。

三、动机

我们可以看到，在去年的机器学习顶会上，已经有一些工作对一开始提出的两个问题进行了一定的研究。这里最为显著的是Stanford的P-GNN [10]和Cornell的GraphZoom [11]。

P-GNN提出了一种新型的GNN范式，整合位置信息，在结点预测任务上的提升是极其显著的，比现有GNN的准确率翻了超过一倍。而GraphZoom则是近些年来第一次将GNN的适用范围推至billion级别的边数，可扩展性远超之前的GNN架构，速度提升最大达到40x加速比。这两篇论文都说明在这波浪潮下，GNN可提升的空间依然很大。

1. 位置感知

GNN无法捕获全局相对的位置信息，导致对于相同的局部结构，其生成的结点嵌入相同，无法区分。而这种结构等价性在分子结构、社交网络上却非常常见，因此有必要将位置信息也考虑在内。

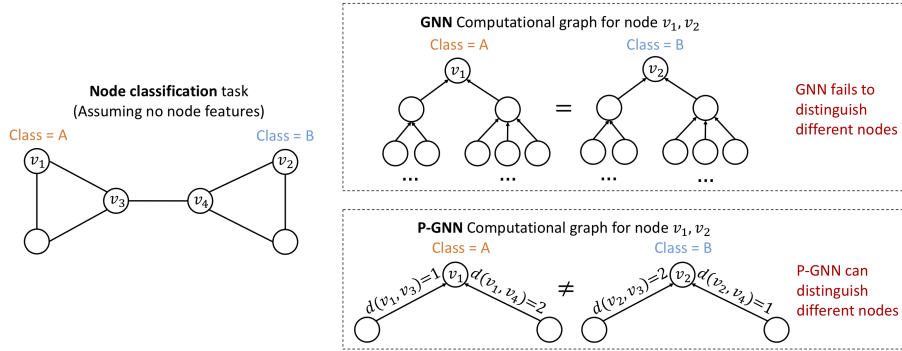


图 4: 结构等价性

P-GNN采用锚点(anchor)集的方式，每次在全图采样随机数目的点（采样方式根据Bourgain定理），把这些点作为邻居进行聚合。给定 $k = c \log^2 n$ 个随机结点集 $S_{i,j} \subset V, i = 1, 2, \dots, \log n, j = 1, 2, \dots, c \log n$ ，其中 $S_{i,j}$ 以 $1/2^i$ 的概率选取，得到的嵌入如下

$$f(v) = \left(\frac{d(v, S_{1,1})}{k}, \frac{d(v, S_{1,2})}{k}, \dots, \frac{d(v, S_{\log n, c \log n})}{k} \right)$$




图 5: P-GNN生成图嵌入方式

这里的insight在于锚点集越大，碰到 v_i 的概率也就越高，获得新的信息却很少，但是有更高的采样效率；而锚点集小，碰到 v_i 的概率也就小，那么信息量也就大，尽管采样效率低。

这是一个权衡。这有点像图层面上的多尺度+空洞卷积，都是为了获得更大的感受野。

进而可以在捕获局部网络特征的同时，保留全局相对位置信息。

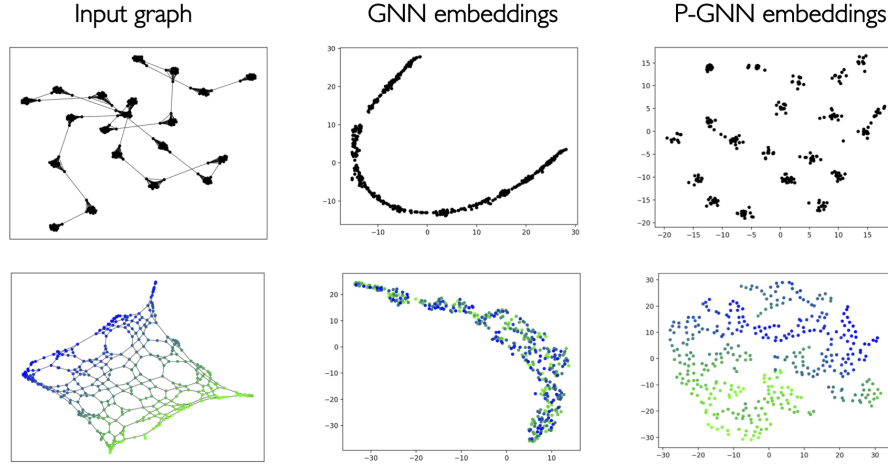


图 6: P-GNN结果可视化

但是这种方法的消息通信复杂度是 $O(mn \log^2 n)$ ，其中 m 为平均锚点集的结点数， n 为图的总结点数；而现有的GNN通信代价一般都为 $O(ne)$ ，所以开销还是非常大的。

为了降低这种开销，P-GNN在计算结点与锚点集的距离时采用 k 跳的截断估计法，事实上要计算SSSP依然开销很大。没有对特征进行处理，事实上特征中也会含有易于区别的位置信息。

2. 多级图嵌入框架

1. 图融合：邻接矩阵+结点嵌入

idea: 基于属性相似度，对原始图做额外的边扩充

- 基于L2范数利用kNN构建属性图
- $A_{fusion} = A_{topo} + \beta A_{feat}$

2. 谱粗化(spectral coarsening): 降维，取特征值大的重构

3. 图嵌入：用现有图嵌入方法对粗化后的图做嵌入，主要是基于随机游走或GNN的方法

4. 嵌入细化：拉普拉斯平滑，映射回原图每一个结点

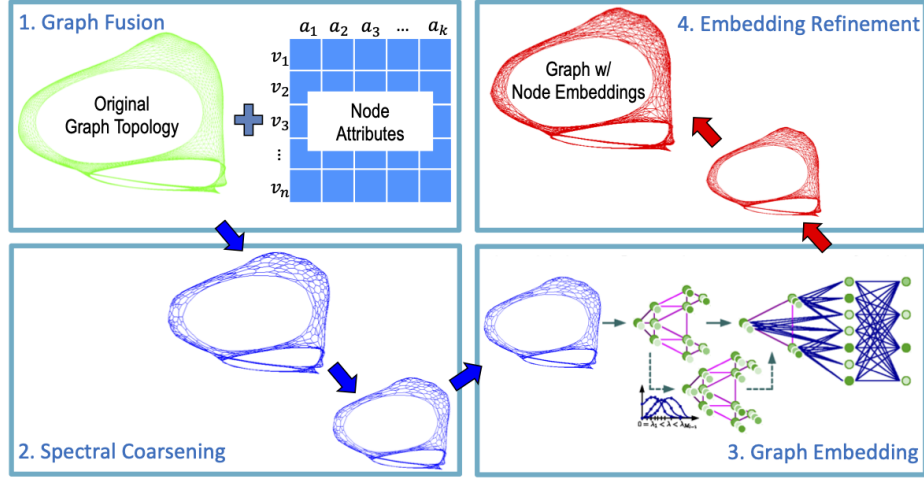


图 7: GraphZoom架构

这种方法很大程度上解决了可扩展性的问题，也证明了多尺度学习方法的有效性。但是这种变化的过程中很可能图的全局结构被破坏了。

四、我们的方法

既要维护位置信息，又要保持高可扩展性，意味着我们的方法不能太复杂。维护位置信息需要兼顾局部和全局，保持高可扩展性又需要。那么可以有以下两点：

- **高采样效率→宽搜广搜结合：**P-GNN采用了一种非常随机的采样方式，尽管覆盖到了大锚点集也覆盖到小锚点集，但是效率太低，采用 k 截断算距离意味着大多数锚点集都是没有用的。其实P-GNN的作者已经提到随机游走和GNN的问题，那么最直接的想法应该是将这两者结合。可以参照node2vec [3]，采用BFS+DFS的方式来进行采样，而这两者的通信代价都只有 $O(|E|)$ 。
- **高可扩展性→多尺度降维与恢复：**降维不失为一种提速的方式，但是核心问题在于在降维后的图准确率会降低。因此怎么降以及怎么恢复是需要考虑的。很多传统CNN的技术，可以尝试挪过来GNN这边使用。比如考虑类似UNet的架构，在恢复过程中复用前面的结果。

参考文献

- [1] B. Perozzi, R. Al-Rfou, and S. Skiena, "DeepWalk: Online learning of social representations," in *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining - KDD '14*, 2014.
- [2] R. Zhu, K. Zhao, H. Yang, W. Lin, C. Zhou, B. Ai, Y. Li, and J. Zhou, "AliGraph: a comprehensive graph neural network platform," 2019.
- [3] A. Grover and J. Leskovec, "node2vec: Scalable feature learning for networks," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining - KDD '16*, 2016.

- [4] K. Yang, M. Zhang, K. Chen, X. Ma, Y. Bai, and Y. Jiang, “KnightKing: a fast distributed graph random walk engine,” in *Proceedings of the 27th ACM Symposium on Operating Systems Principles - SOSP '19*, 2019.
- [5] M. Fey and J. E. Lenssen, “Fast graph representation learning with PyTorch geometric,” 2019.
- [6] T. N. Kipf and M. Welling, “Semi-supervised classification with graph convolutional networks,” in *Proceedings of the International Conference on Learning and Representation (ICLR)*, 2017.
- [7] W. L. Hamilton, R. Ying, and J. Leskovec, “Inductive representation learning on large graphs,” in *Advances in neural information processing systems (NeurIPS)*, 2017.
- [8] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, “Graph attention networks,” in *Proceedings of the International Conference on Learning and Representation (ICLR)*, 2018.
- [9] Y. Li, D. Tarlow, M. Brockschmidt, and R. Zemel, “Gated graph sequence neural networks,” in *Proceedings of the International Conference on Learning and Representation (ICLR)*, 2016.
- [10] J. You, R. Ying, and J. Leskovec, “Position-aware graph neural networks,” in *International Conference on Machine Learning (ICML)*, 2019.
- [11] C. Deng, Z. Zhao, Y. Wang, Z. Zhang, and Z. Feng, “GraphZoom: A multi-level spectral approach for accurate and scalable graph embedding,” 2019.