

# 模式识别作业六

数据科学与计算机学院 17大数据与人工智能

17341015 陈鸿崢

问题 1 (§5 Q4). 考虑判别中用的超平面。

(a) 证明在从超平面  $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0$  到点  $\mathbf{x}_a$  的距离为  $|g(\mathbf{x}_a)| / \|\mathbf{w}\|$ , 且对应的点是约束条件  $g(\mathbf{x}) = 0$  下的满足使  $\|\mathbf{x} - \mathbf{x}_a\|^2$  最小的  $\mathbf{x}$ 。

(b) 证明  $\mathbf{x}_a$  到超平面的投影为

$$\mathbf{x}_p = \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

解答. (a) 优化问题如下

$$\begin{aligned} \min_{\mathbf{x}} \quad & \|\mathbf{x} - \mathbf{x}_a\|^2 \\ \text{s.t.} \quad & g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0 \end{aligned}$$

构造拉格朗日函数（这里为方便计算，在约束项前面添加了常数2）

$$\begin{aligned} f(\mathbf{x}, \lambda) &= \|\mathbf{x} - \mathbf{x}_a\|^2 + 2\lambda[g(\mathbf{x})] \\ &= \|\mathbf{x} - \mathbf{x}_a\|^2 + 2\lambda[\mathbf{w}^T \mathbf{x} + w_0] \\ &= (\mathbf{x} - \mathbf{x}_a)^T (\mathbf{x} - \mathbf{x}_a) + 2\lambda(\mathbf{w}^T \mathbf{x} + w_0) \\ &= \mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{x}_a + \mathbf{x}_a^T \mathbf{x}_a + 2\lambda(\mathbf{x}^T \mathbf{w} + w_0) \end{aligned}$$

分别求偏导有

$$\begin{cases} \frac{\partial f(\mathbf{x}, \lambda)}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{x}_a + \lambda \mathbf{w} = 0 \\ \frac{\partial f(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{w}^T \mathbf{x} + w_0 = 0 \end{cases}$$

联立可解得

$$\lambda = \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}}$$

进而有

$$\begin{aligned} \mathbf{x} &= \mathbf{x}_a - \lambda \mathbf{w} \\ &= \begin{cases} \mathbf{x}_a - \left[ \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right] \mathbf{w} & \mathbf{w} \neq \mathbf{0} \\ \mathbf{x}_a & \mathbf{w} = \mathbf{0} \end{cases} \end{aligned}$$

代入原式得到距离最小值

$$\begin{aligned}\|\mathbf{x} - \mathbf{x}_a\| &= \left\| \mathbf{x}_a - \left[ \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right] \mathbf{w} - \mathbf{x}_a \right\| \\ &= \left\| \left( \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right) \mathbf{w} \right\| \\ &= \frac{|g(\mathbf{x}_a)| \|\mathbf{w}\|}{\|\mathbf{w}\|^2} = \frac{|g(\mathbf{x}_a)|}{\|\mathbf{w}\|}\end{aligned}$$

符合题意

(b) 由于(a)已经得到从超平面到 $\mathbf{x}$ 的最小距离, 而 $\mathbf{x}_a$ 的投影即为拉格朗日求导等于零求出来的 $\mathbf{x}$ 值, 即

$$\begin{aligned}\mathbf{x}_p &= \mathbf{x}_a - \lambda \mathbf{w} \\ &= \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}\end{aligned}$$

其中

$$\lambda = \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2}$$

**问题 2** (§5 Q14). 考虑平方误差和准则函数 (式(43))

$$J_s(\mathbf{a}) = \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b_i)^2$$

令 $b_i = b$ , 取如下6个训练点:

$$\begin{aligned}\omega_1 &: (1, 5)^T & (2, 9)^T & (-5, -3)^T \\ \omega_2 &: (2, -3)^T & (-1, -4)^T & (0, 2)^T\end{aligned}$$

(a) 计算它的Hessian矩阵

(b) 假定二次准则函数, 计算最优学习率 $\eta$

**解答.** 将训练集数据 $\omega_1$ 和 $\omega_2$ 构成矩阵, 并扩增一个维度做规范化, 得到

$$Y = \begin{pmatrix} 1 & 1 & 5 \\ 1 & 2 & 9 \\ 1 & -5 & -3 \\ -1 & -2 & 3 \\ -1 & 1 & 4 \\ -1 & 0 & -2 \end{pmatrix} \quad \mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} b \\ b \\ b \\ b \\ b \\ b \end{pmatrix}$$

平方误差准则函数为

$$J_s(\mathbf{a}) = \frac{1}{2} \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b)^2 = \frac{(Y\mathbf{a} - \mathbf{b})^T (Y\mathbf{a} - \mathbf{b})}{2}$$

(a) 对准则函数求导得到

$$\nabla J_s(\mathbf{a}) = Y^T (Y\mathbf{a} - \mathbf{b})$$

进而Hessian矩阵为

$$H = \nabla^2 J_s(\mathbf{a}) = Y^T Y = \begin{pmatrix} 6 & -1 & 6 \\ -1 & 35 & 36 \\ 6 & 36 & 144 \end{pmatrix}$$

(b) 由公式(14)，最优学习率为

$$\eta = \frac{[\nabla J_s(\mathbf{a})]^T \nabla J_s(\mathbf{a})}{[\nabla J_s(\mathbf{a})]^T H \nabla J_s(\mathbf{a})}$$

通过求解特征方程，得到 $H$ 的特征值<sup>1</sup>为5.417, 24.57, 155.0，进而由二次型的性质<sup>2</sup>

$$\frac{1}{\lambda_{\max}} = 0.006452 \leq \eta \leq 0.1846 = \frac{1}{\lambda_{\min}}$$

**问题 3** (§5 Q21). 证明MSE解法中的尺度因子 $\alpha$ 和Fisher线性判别 (5.8.2节) 的对应关系为

$$\alpha = \left[ 1 + \frac{n_1 n_2}{n} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \right]^{-1}$$

**解答.** 由等式(54)有权重向量

$$\mathbf{w} = \alpha n \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

其中 $\mathbf{w}$ 满足

$$\left[ \frac{1}{n} \mathbf{S}_w + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \right] \mathbf{w} = \mathbf{m}_1 - \mathbf{m}_2$$

将 $\mathbf{w}$ 代入上式得到

$$\left[ \frac{1}{n} \mathbf{S}_w + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \right] \alpha n \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) = \mathbf{m}_1 - \mathbf{m}_2$$

令

$$\theta = 1 + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

<sup>1</sup>特征值可通过 $|H - \lambda I| = 0$ 求解，这里则直接使用numpy指令np.linalg.eig进行计算。

<sup>2</sup>二次型 $Q$ 有 $\min_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \lambda_{\min}$ 和 $\max_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \lambda_{\max}$

则

$$\alpha \theta (\mathbf{m}_1 - \mathbf{m}_2) = \mathbf{m}_1 - \mathbf{m}_2$$

由于这条等式对于所有 $\mathbf{m}_1$ 和 $\mathbf{m}_2$ 成立, 因此我们有 $\alpha \theta = 1$ , 或者下式成立

$$\alpha = \left[ 1 + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \right]^{-1}$$

**问题 4** (§5 Q28). 在5.10.2节给出的线性规划公式包含了一个极小化的人工变量 $\tau$ , 且满足约束条件 $\mathbf{a}^T \mathbf{y}_i + \tau > b_i$ 及 $\tau \geq 0$ 。证明得到的权向量使得以下准则函数极小化:

$$J_\tau(\mathbf{a}) = \max_{\mathbf{a}^T \mathbf{y}_i \leq b_i} [b_i - \mathbf{a}^T \mathbf{y}_i]$$

**解答.** 实际上即找

$$\forall i : \min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\}$$

而目标是使权重向量 $\mathbf{a}$ 最小化准则函数

$$J_t(\mathbf{a}) = \max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i)$$

将其分为线性可分和线性不可分两种情况处理。

(a) 线性可分情况下, 存在 $\mathbf{a}_o$ 使得 $\mathbf{a}_o^T \mathbf{y}_i = b_i$ , 那么显然

$$\forall t > 0, i : \mathbf{a}_o^T \mathbf{y}_i + t > b_i$$

因此我们有对于所有的 $i$

$$\begin{aligned} 0 &\leq \min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} \\ &\leq \min \{t : t \geq 0, \mathbf{a}_o^T \mathbf{y}_i + t > b_i\} = 0 \end{aligned}$$

进而

$$\min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} = 0$$

得到的权重向量即为 $\mathbf{a}_o$ 。由 $J_t(\mathbf{a}) \geq 0, \forall \mathbf{a}$ 且 $J_t(\mathbf{a}_o) = 0$ , 可知

$$\arg \min_{\mathbf{a}} J_t(\mathbf{a}) = \mathbf{a}_o$$

这说明使 $\mathbf{a}$ 最小化 $J_t(\mathbf{a})$ 等价于解决修改后的问题。

(b) 线性不可分下, 不存在 $\mathbf{a}_o$ 使得 $\mathbf{a}_o^T \mathbf{y}_i = b_i$ , 那么

$$\begin{aligned}
 \forall i: \min_{t, \mathbf{a}} \{t: t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} &= \min_{t, \mathbf{a}} \{t: t \geq 0, t > b_i - \mathbf{a}^T \mathbf{y}_i\} \\
 &= \min_{t, \mathbf{a}} \left\{t: t \geq 0, t > \max_i (b_i - \mathbf{a}^T \mathbf{y}_i)\right\} \\
 &= \min_{t, \mathbf{a}} \left\{t: t > 0, t > \max_i (b_i - \mathbf{a}^T \mathbf{y}_i)\right\} \\
 &= \min_{t, \mathbf{a}} \left\{t: t > \max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i)\right\} \\
 &= \min_{t, \mathbf{a}} \left\{\max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i)\right\} \\
 &= \min_{\mathbf{a}} J_t(\mathbf{a})
 \end{aligned}$$

问题 5 (§5 Q32). 考虑支持向量机和分属两类的训练样本:

$$\begin{aligned}
 \omega_1: & (1, 1)^T \quad (2, 2)^T \quad (2, 0)^T \\
 \omega_2: & (0, 0)^T \quad (1, 0)^T \quad (0, 1)^T
 \end{aligned}$$

(a) 在图中作出这6个训练点, 构造具有最优超平面和最优间隔的权向量。

(b) 哪些是支持向量?

(c) 通过寻找拉格朗日待定系数 $\alpha_i$ 来构造在对偶空间的解, 并将它与(a)中的结果比较。


解答. (a) 按序编号

$$\begin{aligned}
 \omega_1: \mathbf{x}_1 &= \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 2 \\ 0 \end{pmatrix} \\
 \omega_2: \mathbf{x}_4 &= \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \mathbf{x}_5 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \mathbf{x}_6 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}
 \end{aligned}$$

且 $z_1 = z_2 = z_3 = -1, z_4 = z_5 = z_6 = 1$ 。如下图所示, 考虑做恒等映射 $\mathbf{y}_k = \varphi(\mathbf{x}_k) = \mathbf{x}_k$ , 则在 $\mathbf{y}$ 空间上最优超平面为 $y_1 + y_2 = 3/2$ , 即

$$(3/2, -1, -1)^T (1, y_1, y_2) = 0$$

将其做放缩变换( $\times 2$ ), 得到权向量为 $(3, -2, -2)^T$ 。



最优间隔为从样本点到超平面的最小距离为  $1/2 \sin(\pi/4) = \sqrt{2}/4$ 。

(b) 从上图可以清晰看出，支持向量为

$$\{\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6\} = \{(1, 1)^T, (2, 0)^T, (1, 0)^T, (0, 1)^T\}$$

(c) 最大化式(109)给出的准则函数

$$L(\alpha) = \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,j} \alpha_k \alpha_j z_k z_j \mathbf{y}_j^T \mathbf{y}_k$$

$$\text{s.t. } \sum_{k=1}^n z_k \alpha_k = 0, \alpha_k \geq 0$$

使用约束条件，可用下式消除一个元

$$\alpha_6 = \alpha_1 + \alpha_2 + \alpha_3 - \alpha_4 - \alpha_5$$

求偏导得到

$$\begin{bmatrix} -1 & -2 & -2 & 0 & 1 \\ -2 & -5 & 2 & -1 & 1 \\ -2 & 2 & -5 & 1 & 1 \\ 0 & -1 & 1 & -1 & -1 \\ 1 & 1 & 3 & -1 & -2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \\ -2 \\ 0 \\ 0 \end{bmatrix}$$

但是这个方程组不相容，因此最大值一定在边界处取到（即有些  $\alpha_i$  消失了）。接下来尝试分别令每一个  $\alpha_i = 0$  来求解。

–  $\alpha_1 = 0$ 时,

$$\frac{\partial L(0, \alpha_2, \alpha_3, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

可解得  $\alpha = (0, -1/10, -1/10, 8/5, -8/5, -4/5)^T$

–  $\alpha_2 = 0$ 时, 下式导致不相容

$$\frac{\partial L(\alpha_1, 0, \alpha_3, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

–  $\alpha_3 = 0$ 时, 下式导致不相容

$$\frac{\partial L(\alpha_1, \alpha_2, 0, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

–  $\alpha_4 = 0$ 时,

$$\frac{\partial L(\alpha_1, \alpha_2, \alpha_3, 0, \alpha_5)}{\partial \alpha_i} = 0$$

解得  $\alpha = 1/5(16, 0, 4, 0, 14, 6)^T$ , 满足  $\alpha_i \geq 0$  的限制, 此时准则函数  $L(\alpha) = 4$

–  $\alpha_5 = 0$ 时,

$$\frac{\partial L(\alpha_1, \alpha_2, \alpha_3, \alpha_4, 0)}{\partial \alpha_i} = 0$$

得到  $\alpha = 1/5(2, 2, 2, 0, 0, 6)^T$ , 满足  $\alpha_i \geq 0$  的限制, 此时准则函数  $L(\alpha) = 1.2$

故  $\alpha = 1/5(16, 0, 4, 0, 14, 6)^T$  时, 准则函数  $L$  取得最大值, 且满足限制条件。

接下来计算权向量  $\mathbf{a}$ 。视  $\mathbf{a}$  为变量, 尝试最小化式(108)中的

$$L(\mathbf{a}, \alpha) = \frac{1}{2} \|\mathbf{a}\|^2 - \sum_{k=1}^n \alpha_k [z_k \mathbf{a}^T \mathbf{y}_k - 1]$$

求导有

$$\frac{\partial L}{\partial \mathbf{a}} = \mathbf{a} - \sum_{k=1}^n \alpha_k z_k \mathbf{y}_k = \mathbf{0}$$

进而  $\mathbf{a} = (a_0, -2, -2)^T$ 。

最后确定  $a_0$ 。使用支持向量  $\mathbf{y} = (1, 1, 1)^T$ , 满足  $\mathbf{a}^T \mathbf{y}_1 z_1 = 1$ , 得到

$$-\begin{pmatrix} a_0 \\ -2 \\ -2 \end{pmatrix} (1, 1, 1) = -a_0 + 4 = 1$$

求得  $a_0 = 3$ , 最终的权向量为  $\mathbf{a} = (3, -2, -2)^T$ 。