

模式识别作业六

数据科学与计算机学院 17大数据与人工智能

17341015 陈鸿崢

问题 1 (§5 Q4). 考虑判别中用的超平面。

(a) 证明在从超平面 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0$ 到点 \mathbf{x}_a 的距离为 $|g(\mathbf{x}_a)| / \|\mathbf{w}\|$ ，且对应的点是约束条件 $g(\mathbf{x}) = 0$ 下的满足使 $\|\mathbf{x} - \mathbf{x}_a\|^2$ 最小的 \mathbf{x} 。

(b) 证明 \mathbf{x}_a 到超平面的投影为

$$\mathbf{x}_p = \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

解答. (a) 构造拉格朗日函数

$$\begin{aligned} f(\mathbf{x}, \lambda) &= \|\mathbf{x} - \mathbf{x}_a\|^2 + 2\lambda[g(\mathbf{x})] \\ &= \|\mathbf{x} - \mathbf{x}_a\|^2 + 2\lambda[\mathbf{w}^T \mathbf{x} + w_0] \\ &= (\mathbf{x} - \mathbf{x}_a)^T (\mathbf{x} - \mathbf{x}_a) + 2\lambda(\mathbf{w}^T \mathbf{x} + w_0) \\ &= \mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{x}_a + \mathbf{x}_a^T \mathbf{x}_a + 2\lambda(\mathbf{x}^T \mathbf{w} + w_0) \end{aligned}$$

分别求偏导有

$$\begin{cases} \frac{\partial f(\mathbf{x}, \lambda)}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{x}_a + \lambda \mathbf{w} = 0 \\ \frac{\partial f(\mathbf{x}, \lambda)}{\partial \lambda} = \mathbf{w}^T \mathbf{x} + w_0 = 0 \end{cases}$$

联立可解得

$$\lambda = \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}}$$

进而有

$$\begin{aligned} \mathbf{x} &= \mathbf{x}_a - \lambda \mathbf{w} \\ &= \begin{cases} \mathbf{x}_a - \left[\frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right] \mathbf{w} & \mathbf{w} \neq \mathbf{0} \\ \mathbf{x}_a & \mathbf{w} = \mathbf{0} \end{cases} \end{aligned}$$

代入原式得到距离最小值

$$\begin{aligned} \|\mathbf{x} - \mathbf{x}_a\| &= \left\| \mathbf{x}_a - \left[\frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right] \mathbf{w} - \mathbf{x}_a \right\| \\ &= \left\| \left(\frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} \right) \mathbf{w} \right\| \\ &= \frac{|g(\mathbf{x}_a)| \|\mathbf{w}\|}{\|\mathbf{w}\|^2} = \frac{|g(\mathbf{x}_a)|}{\|\mathbf{w}\|} \end{aligned}$$

(b) 由于(a)已经得到从超平面到 \mathbf{x} 的最小距离，而 \mathbf{x}_a 的投影即为拉格朗日求导等于零求出来

的 \mathbf{x} 值, 即

$$\begin{aligned}\mathbf{x}_p &= \mathbf{x}_a - \lambda \mathbf{w} \\ &= \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}\end{aligned}$$

其中

$$\lambda = \frac{\mathbf{w}^T \mathbf{x}_a + w_0}{\mathbf{w}^T \mathbf{w}} = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2}$$

问题 2 (§5 Q14). 考虑平方误差和准则函数 (式(43))

$$J_s(\mathbf{a}) = \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b_i)^2$$

令 $b_i = b$, 取如下6个训练点:

$$\begin{aligned}\omega_1 &: (1, 5)^T & (2, 9)^T & (-5, -3)^T \\ \omega_2 &: (2, -3)^T & (-1, -4)^T & (0, 2)^T\end{aligned}$$

(a) 计算它的Hessian矩阵

(b) 假定二次准则函数, 计算最优学习率 η

解答. 将训练集数据 ω_1 和 ω_2 构成矩阵, 并扩增一个维度, 得到

$$Y = \begin{pmatrix} 1 & 1 & 5 \\ 1 & 2 & 9 \\ 1 & -5 & -3 \\ -1 & -2 & 3 \\ -1 & 1 & 4 \\ -1 & 0 & -2 \end{pmatrix} \quad \mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} b \\ b \\ b \\ b \\ b \\ b \end{pmatrix}$$

平方误差准则函数为

$$\mathbf{J}_s(\mathbf{a}) = \frac{1}{2} \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b)^2 = \frac{(Y\mathbf{a} - \mathbf{b})^T (Y\mathbf{a} - \mathbf{b})}{2}$$

(a) 对准则函数求导得到

$$\nabla J_s(\mathbf{a}) = Y^T (Y\mathbf{a} - \mathbf{b}) = \begin{pmatrix} 6a_1 & - & a_2 & + & 6a_3 & + & 0 \\ -a_1 & + & 35a_2 & + & 36a_3 & + & 3b \\ 6a_1 & + & 36a_2 & + & 144a_3 & - & 16b \end{pmatrix}$$

进而Hessian矩阵为

$$H = Y^T Y = \begin{pmatrix} 6 & -1 & 6 \\ -1 & 35 & 36 \\ 6 & 36 & 144 \end{pmatrix}$$

(b) 最优学习率

$$\eta = \frac{[\nabla J_s(\mathbf{a})]^T \nabla J_s(\mathbf{a})}{[\nabla J_s(\mathbf{a})]^T H \nabla J_s(\mathbf{a})}$$

通过求解特征方程，得到 \mathbf{H} 的特征值为5.417, 24.57, 155.0，进而 $0.006452 \leq \eta \leq 0.1846$

问题 3 (§5 Q21). 证明MSE解法中的尺度因子 α 和Fisher线性判别 (5.8.2节) 的对应关系为

$$\alpha = \left[1 + \frac{n_1 n_2}{n} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \right]^{-1}$$

解答. 由等式(54)有权重向量

$$\mathbf{w} = \alpha n \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

其中 \mathbf{w} 满足

$$\left[\frac{1}{n} \mathbf{S}_w + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \right] \mathbf{w} = \mathbf{m}_1 - \mathbf{m}_2$$

将 \mathbf{w} 代入上式得到

$$\left[\frac{1}{n} \mathbf{S}_w + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T \right] \alpha n \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) = \mathbf{m}_1 - \mathbf{m}_2$$

进而

$$\alpha \theta (\mathbf{m}_1 - \mathbf{m}_2) = \mathbf{m}_1 - \mathbf{m}_2$$

其中

$$\theta = 1 + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)$$

由于这条等式对于所有 \mathbf{m}_1 和 \mathbf{m}_2 成立，因此我们有 $\alpha \theta = 1$ ，或者下式成立

$$\alpha = \left[1 + \frac{n_1 n_2}{n^2} (\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \right]^{-1}$$

问题 4 (§5 Q28). 在5.10.2节给出的线性规划公式包含了一个极小化的人工变量 τ ，且满足约束条件 $\mathbf{a}^T \mathbf{y}_i + \tau > b_i$ 及 $\tau \geq 0$ 。证明得到的权向量使得以下准则函数极小化：

$$J_\tau(\mathbf{a}) = \max_{\mathbf{a}^T \mathbf{y}_i \leq b_i} [b_i - \mathbf{a}^T \mathbf{y}_i]$$

解答. 实际上即找

$$\forall i : \min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\}$$

而目标是使权重向量 \mathbf{a} 最小化准则函数

$$J_t(\mathbf{a}) = \max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i)$$

将其分为线性可分和线性不可分两种情况处理。

(a) 线性可分情况下, 存在 \mathbf{a}_o 使得 $\mathbf{a}_o^T \mathbf{y}_i = b_i$, 那么显然

$$\forall t > 0, i : \mathbf{a}_o^T \mathbf{y}_i + t > b_i$$

因此我们有对于所有的 i

$$\begin{aligned} 0 &\leq \min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} \\ &\leq \min \{t : t \geq 0, \mathbf{a}_o^T \mathbf{y}_i + t > b_i\} = 0 \end{aligned}$$

进而

$$\min \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} = 0$$

得到的权重向量即为 \mathbf{a}_o 。由 $J_t(\mathbf{a}) \geq 0, \forall \mathbf{a}$ 且 $J_t(\mathbf{a}_o) = 0$, 可知

$$\arg \min_{\mathbf{a}} J_t(\mathbf{a}) = \mathbf{a}_o$$

这说明使 \mathbf{a} 最小化 $J_t(\mathbf{a})$ 等价于解决修改后的问题。

(b) 线性不可分下, 不存在 \mathbf{a}_o 使得 $\mathbf{a}_o^T \mathbf{y}_i = b_i$, 那么

$$\begin{aligned} \forall i : \min_{t, \mathbf{a}} \{t : t \geq 0, \mathbf{a}^T \mathbf{y}_i + t > b_i\} &= \min_{t, \mathbf{a}} \{t : t \geq 0, t > b_i - \mathbf{a}^T \mathbf{y}_i\} \\ &= \min_{t, \mathbf{a}} \left\{ t : t \geq 0, t > \max_i (b_i - \mathbf{a}^T \mathbf{y}_i) \right\} \\ &= \min_{t, \mathbf{a}} \left\{ t : t > 0, t > \max_i (b_i - \mathbf{a}^T \mathbf{y}_i) \right\} \\ &= \min_{t, \mathbf{a}} \left\{ t : t > \max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i) \right\} \\ &= \min_{t, \mathbf{a}} \left\{ \max_{i: \mathbf{a}^T \mathbf{y}_i \leq b_i} (b_i - \mathbf{a}^T \mathbf{y}_i) \right\} \\ &= \min_{\mathbf{a}} J_t(\mathbf{a}) \end{aligned}$$

问题 5 (§5 Q32). 考虑支持向量机和分属两类的训练样本:

$$\omega_1: (1, 1)^T \quad (2, 2)^T \quad (2, 0)^T$$

$$\omega_2: (0, 0)^T \quad (1, 0)^T \quad (0, 1)^T$$

(a) 在图中作出这6个训练点，构造具有最优超平面和最优间隔的权向量。

(b) 哪些是支持向量？

(c) 通过寻找拉格朗日待定系数 α_i 来构造在对偶空间的解，并将它与(a)中的结果比较。

解答. (a) 按序编号


$$\omega_1: \mathbf{x}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}$$

$$\omega_2: \mathbf{x}_4 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \mathbf{x}_5 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \mathbf{x}_6 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

且 $z_1 = z_2 = z_3 = -1, z_4 = z_5 = z_6 = 1$ 。最优超平面为 $y_1 + y_2 = 3/2$ ，即

$$(3/2, -1, -1)^T (1, y_1, y_2) = 0$$

将其做放缩变换($\times 2$)，得到权向量为 $(3, -2, -2)^T$ 。



最优间隔为从样本点到超平面的最小距离，如上图所示，为 $\sqrt{2}/4$ 。

(b) 从上图可以清晰看出，支持向量为

$$\{\mathbf{x}_1, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6\} = \{(1, 1)^T, (2, 0)^T, (1, 0)^T, (0, 1)^T\}$$

(c) 最大化式(109)给出的准则函数

$$L(\boldsymbol{\alpha}) = \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,j} \alpha_k \alpha_j z_k z_j \mathbf{y}_j^T \mathbf{y}_k$$

$$\text{s.t. } \sum_{k=1}^n z_k \alpha_k = 0, \alpha_k \geq 0$$

使用约束条件, 可用下式消除一个元

$$\alpha_6 = \alpha_1 + \alpha_2 + \alpha_3 - \alpha_4 - \alpha_5$$

求偏导得到

$$\begin{bmatrix} -1 & -2 & -2 & 0 & 1 \\ -2 & -5 & 2 & -1 & 1 \\ -2 & 2 & -5 & 1 & 1 \\ 0 & -1 & 1 & -1 & -1 \\ 1 & 1 & 3 & -1 & -2 \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \\ -2 \\ 0 \\ 0 \end{bmatrix}$$

但是这个方程组不相容, 因此最大值一定在边界处取到 (即有些 α_i 消失了)。接下来尝试分别令每一个 $\alpha_i = 0$ 来求解。

– $\alpha_1 = 0$ 时,

$$\frac{\partial L(0, \alpha_2, \alpha_3, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

可解得 $\boldsymbol{\alpha} = (0, -1/10, -1/10, 8/5, -8/5, -4/5)^T$

– $\alpha_2 = 0$ 时, 下式导致不相容

$$\frac{\partial L(\alpha_1, 0, \alpha_3, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

– $\alpha_3 = 0$ 时, 下式导致不相容

$$\frac{\partial L(\alpha_1, \alpha_2, 0, \alpha_4, \alpha_5)}{\partial \alpha_i} = 0$$

– $\alpha_4 = 0$ 时,

$$\frac{\partial L(\alpha_1, \alpha_2, \alpha_3, 0, \alpha_5)}{\partial \alpha_i} = 0$$

解得 $\boldsymbol{\alpha} = 1/5(16, 0, 4, 0, 14, 6)^T$, 满足 $\alpha_i \geq 0$ 的限制, 此时准则函数 $L(\boldsymbol{\alpha}) = 4$

– $\alpha_5 = 0$ 时,

$$\frac{\partial L(\alpha_1, \alpha_2, \alpha_3, \alpha_4, 0)}{\partial \alpha_i} = 0$$

得到 $\boldsymbol{\alpha} = 1/5(2, 2, 2, 0, 0, 6)^T$ ，满足 $\alpha_i \geq 0$ 的限制，此时准则函数 $L(\boldsymbol{\alpha}) = 1.2$

故 $\boldsymbol{\alpha} = 1/5(16, 0, 4, 0, 14, 6)^T$ 时，准则函数 L 取得最大值，且满足限制条件。

接下来计算权向量 \mathbf{a} 。视 \mathbf{a} 为变量，尝试最小化式(108)中的

$$L(\mathbf{a}, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{a}\|^2 - \sum_{k=1}^n \alpha_k [z_k \mathbf{a}^T \mathbf{y}_k - 1]$$

求导有

$$\frac{\partial L}{\partial \mathbf{a}} = \mathbf{a} - \sum_{k=1}^n \alpha_k z_k \mathbf{y}_k = \mathbf{0}$$

进而 $\mathbf{a} = (0, -2, -2)^T$ 。

最后确定 a_0 。使用支持向量 $\mathbf{y} = (1, 1, 1)^T$ ，满足 $\mathbf{a}^T \mathbf{y}_1 z_1 = 1$ ，得到

$$-\begin{pmatrix} 0 \\ -2 \\ -2 \end{pmatrix} (1, 1, 1) = -a_0 + 4 = 1$$

求得 $a_0 = 3$ ，最终的权向量为 $\mathbf{a} = (3, -2, -2)^T$ 。